ML Pipeline Project

1 Istruzioni

- L'intero progetto sarà valutato e contribuirà per il 50% al voto finale.
- È richiesto di consegnare il codice sul quale va lavorato (preferibilmente Python notebooks). Non va scritta una relazione finale. Tuttavia, i codici devono contenere commenti e spiegazione delle procedure adottate.
- Non sarete valutati sulla qualità finale delle performance, ma su: i) correttezza dell'implementazione; ii) qualità dei commenti e delle osservazioni; iii) correttezza scientifica dei passaggi eseguiti.
- Si prega di inviare un unico file .zip contenente tutti gli script realizzati.
- Il file .zip andrà caricato su iCorsi. La scadenza sarà fissata al **20 Dicembre, ore 23:59**.
- Potete discutere del progetto con i vostri compagni, ma siete tenuti a svolgere il progetto in prima persona. Plagio nel codice sorgente o nei commenti è punito da regolamento istituzionale con un voto pari a 0 e potrà essere segnalato alla facoltà.
- Siete assolutamente incoraggiati a chiedermi chiarimenti su qualsiasi parte non vi sia chiara. Sentitevi liberi di contattarmi per suggerimenti o feedback.

2 Requisiti del progetto

- L'obiettivo generale è costruire una semplice pipeline di machine learning per **classificazione o regressione**, utilizzando un **dataset reale** trovato online. L'obiettivo è esercitarsi nella costruzione di sistemi ML end-to-end, dall'acquisizione dei dati fino alla valutazione del modello.

2.1 Selezione del dataset

– Scegliere un dataset da una fonte pubblica (es. Kaggle, UCI ML Repository, OpenML, data.gov).

– Il dataset deve essere adatto alla classificazione **e/o** alla regressione.

– Descrivere brevemente il dataset: cosa contiene, la sua origine e la variabile target.

2.2 Preprocessing dei dati

- Gestire i valori mancanti (es. imputazione o rimozione).
- Normalizzare o standardizzare le variabili numeriche.
- Codificare le variabili categoriche (se presenti).
- Opzionale, eseguire selezione delle feature o riduzione della dimensionalità (es. LASSO).

2.3 Modeling

- Scegliere almeno **due modelli di ML differenti** tra quelli visti a lezione.
- Usare in modo appropriato **train-test split** e/o **cross-validation**.
- Eseguire tuning dei parametri (`GridSearchCV` o `RandomizedSearchCV`).
- Applicare Bagging o un qualche tipo di ensemble (es. `VotingClassifier`).

2.4 Valutazione

- Utilizzare metriche appropriate:
  - Per la classificazione: accuracy, precision, recall, F1-score, matrice di confusione.
  - Per la regressione: MSE, RMSE, MAE, R^2.
- Includere qualche visualizzazioni dei risultati (es. curva ROC, matrici di confusione, feature importance).

2.5 Breve discussione

- Interpretare i risultati: cosa ha funzionato bene, cosa no?
- Cosa faresti con più tempo o più dati?

2.6 Punti bonus (facoltativi)

- Provare a utilizzare una pipeline tramite la classe `Pipeline` di `scikit-learn`.
- Includere visualizzazioni con strumenti come `UMAP` o `SHAP`.

3 Presentazione in aula

- Presentazione PowerPoint (o simile).
- Durata: circa 12 minuti, seguiti da 3 minuti per le domande. La durata potrebbe variare leggermente a seconda del numero totale di progetti.